

Entregable 2 big data

November 2025

El proyecto se estructura siguiendo un pipeline de datos end-to-end, es decir, un proceso integral de principio a fin formado por varias etapas hasta alcanzar una solución completa, robusta y escalable. Este flujo de trabajo permite transformar sistemáticamente los datos brutos en insights de negocio accionables, recomendaciones estratégicas y un plan de mejora para la empresa FinPlus.

Tras una fase inicial de análisis de negocio exhaustivo, la profunda comprensión del contexto de la empresa y la definición clara de los objetivos que se abordarán como consultoría especializada, se procede al diseño y ejecución de un proyecto estructurado. Este se compone de múltiples fases secuenciales en las que se emplea un conjunto de arquitecturas modernas, herramientas especializadas con el fin de crear un plan de negocio óptimo para FinPlus.

Esquema general del trabajo

En la siguiente imagen se muestra un diagrama de arquitectura unificado que explica de manera clara y visual cómo fluyen los datos desde los archivos CSV iniciales (CLIENTS.csv y BEHAVIOURAL.csv) hasta su visualización con el objetivo de lograr una toma de decisiones informadas. Este recorrido incluye etapas críticas de limpieza, transformación, enriquecimiento, almacenamiento y agregación de los datos, realizadas mediante el uso de herramientas como PySpark y un entorno Docker estandarizado. Finalmente, tras un análisis exploratorio se generarán conclusiones y recomendaciones estratégicas.




Figura 1: Diagrama general

- Inicialmente, se dispone de dos archivos csv, un primero llamado CLIENTS.csv con la información demográfica y contractual, y un segundo archivo llamado BEHAVIOURAL.csv que contiene el comportamiento digital y transaccional.
- El primer paso es la creación de un entorno Docker con Pyspark con tal de que todo el equipo pueda trabajar en el mismo entorno y pueda ejecutarlo igual.

Docker permite la creación de contenedores donde se dispone de un sistema operativo con Python y sus respectivas librerías, como Pyspark que permite trabajar con datasets grandes y hacer ETLs eficientes.

En el entorno Docker se inicia el proceso ETL con el que se extraen, transforman y cargan los datos para apoyar la evolución del negocio.

Para el análisis de un gran volumen de datos se comienza por la ingesta, de manera que se lean los archivos mencionados anteriormente para a continuación ser tratados y procesados.

A continuación se iniciaría la fase de procesamiento, donde se realizan las tareas de limpieza y transformación de los datos, tratando, por ejemplo, valores nulos, duplicados o validación de formatos, etc.

Una vez los datos iniciales han sido tratados se transforman en los llamados curated datasets que sustituyen a los datasets en bruto. Estos nuevos conjuntos de datos son los utilizados para el análisis y la visualización.

- En la fase de almacenamiento se guardan los curated datasets para su posterior exploración.
- En la capa de análisis se extrae valor a los datos creando un Notebook con las diferentes funciones analíticas con las que obtener estadísticas descriptivas.

Se analizarían, por ejemplo, la actividad del cliente, el valor económico, la fidelidad o los riesgos, entre otros con tal de encontrar oportunidades.

- Una vez realizado el proceso anterior se realiza la visualización con tal de explicar y entender el análisis. Para ello se utiliza la herramienta Power BI pues proporciona visualizaciones interactivas de forma sencilla.
- El proceso culminaría con la realización del informe donde se exponen los insights, es decir, los hallazgos significativos que permiten entender qué está ocurriendo en la empresa y por qué. Después de la identificación de los patrones, tendencias o problemas se generan recomendaciones que proporcionen una manera viable de mejorar el comercio.

Roles y responsabilidades

Para lograr una adecuada organización y coordinación, a los implicados en la consultora de Big Data se les asigna un rol con sus respectivas tareas.

- Project architect: Adriana Ballester Olmo

Coordina el trabajo del equipo, se asegura de que se realicen las tareas y se cumplan los plazos marcados y acordados y los requisitos establecidos. Asimismo, revisa los entregables comprobando que contienen toda la información necesaria.

- Data Engineer: Olga Reus Terrón

Responsable de construir el entorno colaborativo con Docker, el pipeline ETL, gestionar la ingesta, limpieza, transformación y el almacenamiento de los datos, preparando los datasets finales utilizados para el análisis, verificando su calidad.

- Data Analyst: Paula Andrea Monrabal Cutanda

Se encarga del análisis en el notebook. Analiza el comportamiento de los clientes, identificando patrones y conductas extrayendo insights relevantes para el negocio a partir de la visualización de dichos datos.

La fase final del acuerdo de conclusiones y recomendaciones es llevada a cabo en conjunto por todos los miembros del equipo bajo la supervisión del project architect. Así como, la elaboración de una presentación ejecutiva para exponer el problema y enfoque, las tecnologías y procedimientos utilizados, los resultados y visualizaciones y los insights y recomendaciones para la empresa.

Planificación

Por último, el equipo acuerda el siguiente timeline con los hitos y milestones para asegurar la realización a tiempo de todas las fases de este trabajo.

Fechas	Tareas	Hitos
Semana 1	Análisis del negocio, comprendiendo el contexto de la empresa FinPlus, definiendo el problema y marcando los objetivos. Asimismo, se realiza el diseño del proyecto, diferenciando las distintas fases, los roles del equipo y elaborando un cronograma para una adecuada planificación.	Al finalizar la semana se comparte y revisa el entregable de la propuesta inicial y el entregable del diagrama y cronograma.
Semana 2	Se construye el entorno colaborativo en Docker y se realiza el ETL para el tratamiento de datos, se almacenan y se realiza la fase de análisis con Pyspark.	Al finalizar la semana se revisaran los códigos y los resultados obtenidos con tal de asegurarse de que se tiene lo necesario para iniciar la siguiente fase.
Semana 3	A partir de los resultados anteriores se procede a la visualización y se concluye el proyecto con insights y recomendaciones para la empresa. Elaborando una presentación que resume todo el proceso realizado.	Al finalizar la semana el proyecto debe estar acabado con su respectiva presentación.

Cuadro 1: Cronograma de trabajo